Esther Garate
Laura de Luis

MÓDULO 8: Modelización predictiva
Ejercicio 1: modelo supervisado por k vecinos

Contenido

Esther Garate
Laura de Luis

A) "from sklearn.datasets import load_digits" (avanzado)

1) Partiendo de los ejemplos de código Python empleados en clase, elige por favor uno de los siguientes conjuntos de datos y describe qué representan sus campos:

El dataset contiene imágenes de números escritos a mano.
Este dataset describe pixeles de imágenes codificados con valores numéricos del 0 al 16. Consta de 5620 registros y tiene 64 características para cada registro. Las etiquetas son valores numéricos del 0 al 9.

Los datos se han extraído y normalizado a partir de mapas de bit de dígitos escritos a mano. Los mapas de bits de 32x32 se dividen en bloques no superpuestos de 4x4 y se cuenta el número de pixeles en cada bloque, esto genera una matriz de 8x8 de números enteros en un rango del 1 al 16

2) Describe el dataset en dimensiones como en número de características, número de categorías y número de las muestras por categoría utilizando Python.

```
Data Set Characteristics:
   :Number of Instances: 5620
   :Number of Attributes: 64
   :Attribute Information: 8x8 image of integer pixels in the range 0..16.
   :Missing Attribute Values: None
   :Creator: E. Alpaydin (alpaydin '@' boun.edu.tr)
   :Date: July; 1998
```

Tiene 64 categorías que representan cada una un píxel del cuadrante de la imagen de 8x8. Son un número entero con un valor de 0 a 16. En total hay 5620 instancias repartidas en 10 clases (imágenes de un número del 0 al 9).

```
from sklearn.datasets import load_digits
data=load_digits()
print('Description: ' + data.DESCR)
print('target names : ')
print(data.target_names)
X=data.data #creo la matriz X
Y=data.target # vector Y de las etiquetas
print('ceros de las etiquetas ' + str(sum(Y==0)))
print('unos de las etiquetas ' + str(sum(Y==1)))
print('doses de las etiquetas ' + str(sum(Y==2)))
print('treses de las etiquetas ' + str(sum(Y==3)))
print('cuatros de las etiquetas ' + str(sum(Y==4)))
print('cincos de las etiquetas ' + str(sum(Y==5)))
print('seises de las etiquetas ' + str(sum(Y==6)))
print('sietes de las etiquetas ' + str(sum(Y==7)))
print('ochos de las etiquetas ' + str(sum(Y==8)))
print('nueves de las etiquetas ' + str(sum(Y==9)))
```

```
[…]
target names :
[0 1 2 3 4 5 6 7 8 9]
ceros de las etiquetas 178
unos de las etiquetas 182
doses de las etiquetas 177
treses de las etiquetas 183
cuatros de las etiquetas 181
cincos de las etiquetas 182
seises de las etiquetas 181
sietes de las etiquetas 179
ochos de las etiquetas 174
nueves de las etiquetas 180
```

Podemos observar cuantas muestras hay por clase en la salida del código.

Esther Garate
Laura de Luis

3) Repite cada uno de los experimentos vistos en clase, razonando cada uno de los pasos y comentando los resultados parciales obtenidos con el dataset seleccionado

KNN1

Aplicación del modelo k-vecinos habiendo estratificado y dividido el dataset para aplicar una validación con la función StratifiedShuffleSplit().

```
from sklearn.datasets import load_digits
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
import matplotlib.pyplot as plt
datadigits = load_digits()

X= datadigits.data
Y= datadigits.target
from sklearn.model_selection import StratifiedShuffleSplit
#importa el método de la librería
#Este método provee de un índice de train y test para partir el dataset en sus partes correspondientes.
# StratifiedShuffleSplit(self, n_splits=10, test_size="default", train_size=None, random_state=None)
#self: default=10, número de re-shufling y splitting iterations
#test_size: Opcional. float ente 0.0 y 1.0. Representa la proporción del dataset incluida en el corte de test
#train_size: Opcional. float entre 0.0 y 1.0. Representa la proposción del dataset incluida en el corte de train
#random_state: default=None. Es la semilla utilizada por el generador de números random.
n=1 #o 20 para el otro ejemplo
misss=StratifiedShuffleSplit(n,0.3)  #n cortes y una proporción del 30% de la parte de test
fallos=[] #inicializa un array para guardar la suma de los fallos de la predicción
index=0 #inicializa una variable para el índice
for train_index, test_index in misss.split(X, Y): #inicia un bucle for: para el índice de train y el de test en el método de corte StratifiedShuffleSplit
   print (index) #imprime por pantalla el indice
   print (train_index) #imprime por pantalla el índice de train
   print (test_index) #imprime por pantalla el índice de index
   Xtrain=X[train_index,:]  #crea una matriz con los datos de train. Utilizando el índice obtenido
   Xtest=X[test_index,:] #Hace lo mismo con la parte de test
   Ytrain=Y[train_index] #Y repite la operación con el vector Y de train
   Ytest=Y[test_index] #y de test
   miKvecinos=KNeighborsClassifier(n_neighbors=3)
```

Esther Garate
Laura de Luis

```
   #implementa el clasificador del voto de los k vecinos más cercanos
   #KNeighborsClassifier(n_neighbors=5, weights='uniform', algorithm='auto',
leaf_size=30, p=2, metric='minkowski', metric_params=None, n_jobs=1, **kwargs)
  #n_neighbors: Opcional, default=5 número de vecinos
  #algorithm: Opcional, el algoritmo utilizado para computar los vecinos más cercanos:
          #ball_tree -> BallTree
          #kd_tree -> KDTree
          #brute ->usara fuerza bruta para la búsqueda
          #auto -> utilizará el que considere más apropiado
   miKvecinos.fit(Xtrain,Ytrain) #entrenas el modelo con la matriz X y las etiquetas de
entrenamiento
   Ypred=miKvecinos.predict(Xtest) #obtienes una predicción con la parte reservada para
el test
   fallos.append(sum(Ypred!=Ytest)) #un contador de los fallos en la predicción
   index=index+1 #aumenta el índice, pasando al siguiente y avanzando el bucle
   print("fallos: "+str(fallos))
  print ("Num. medio de errores de: " + str(100*np.mean(fallos)/len(Ytest))) #imprime por
pantalla la media
print ("Dev. Std. de errores de: " + str(100*np.std(fallos)/len(Ytest))) #imprime por
pantalla la desviación
```

Aplicamos la función **StratifiedShuffleSplit** con sólo **un corte (Split)** y seleccionando un 30% del dataset para el test :

$$\sigma = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2}$$

```
Num. medio de errores de: 1.2962962963
Dev. Std. de errores de: 0.0
```

El número medio de errores al sólo haber hecho un corte no es un dato a tener en cuenta ya que dependiendo de la muestra de validación puede variar mucho el resultado.

Al haber hecho sólo un corte aleatorio en el dataset el resultado de la media y la desviación no es un dato relevante ya que depende de la distribución original de los datos dentro del dataset.
La desviación es nula por la misma razón.
En este caso el número medio de errores es un dato bastante óptimo, es un dataset grande y su distribución es equilibrada.

Usando la función **StratifiedShuffleSplit** con **20** para el número de cortes y 0.3 para el test.

```
        Resultado
Num. medio de errores de: 1.28703703704
Dev. Std. de errores de: 0.550828656212
```

Esther Garate
Laura de Luis

Conclusión:

Los resultados sobre el número medio de errores no varían mucho haciendo un solo Split o haciendo 20, por lo que podemos deducir que la distribución del dataset es buena, los datos están muy mezclados.

Gráfica de los resultados

```
#Gráfica con la media de los errores y la desviación dependiendo
#del número de splits que apliquemos y con kvecinos=3
desv=[]
error=[]
for n in range(1,30):
    misss=StratifiedShuffleSplit(n,0.3)  #20 cortes y una proporción del 30% de la parte de
test
    fallos=[]
    index=0
    for train_index, test_index in misss.split(X, Y):
        Xtrain=X[train_index,:]
        Xtest=X[test_index,:]
        Ytrain=Y[train_index]
        Ytest=Y[test_index]
        miKvecinos=KNeighborsClassifier(n_neighbors=3)
        miKvecinos.fit(Xtrain,Ytrain)
        Ypred=miKvecinos.predict(Xtest)
        fallos.append(sum(Ypred!=Ytest))
        index=index+1
    error.append(100*np.mean(fallos)/len(Ytest))
    desv.append(100*np.std(fallos)/len(Ytest))

plt.plot(range(1,30),error, 'b-', label='Num. medio de errores')
plt.plot(range(1,30), desv, 'r-', label='Desv. Std de errores')
plt.legend(loc='upper right')
plt.xlabel('Num. splits')
plt.title('Análisis media/varianza/splits')
plt.ylim(0,4)
plt.style.context('seaborn-whitegrid')
```

Esther Garate
Laura de Luis

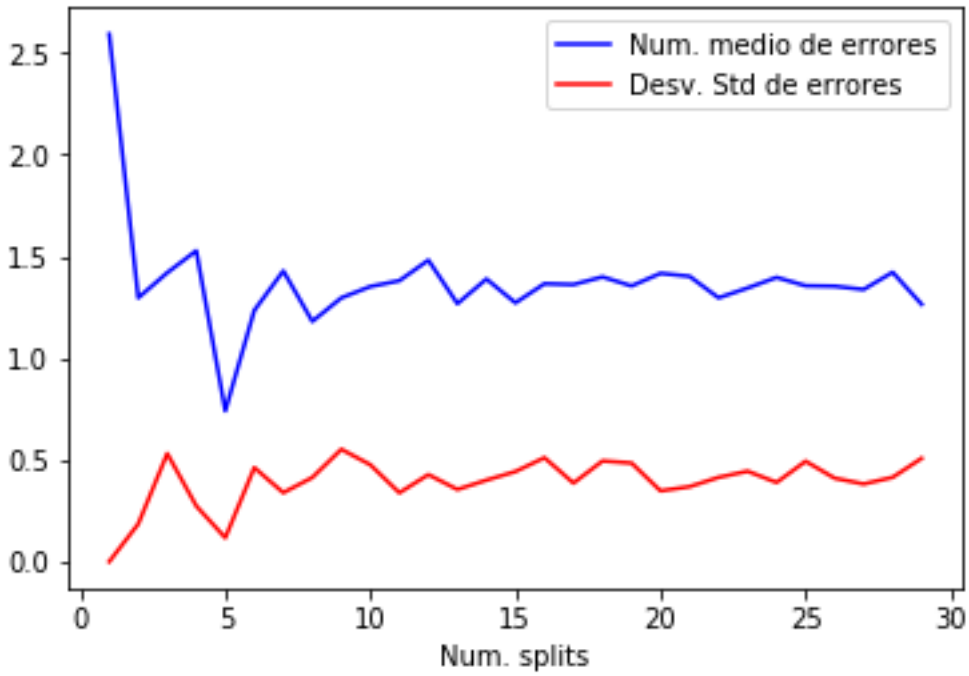

Al visualizar los datos en la gráfica se observa que a partir de 5 splits los datos de la media y desviación empiezan a estabilizarse. Sería óptimo usar un número de splits mayor de 5 para obtener resultados con este dataset con el modelo de KNN.

KNN2

Aplicación del modelo cross_val_score que efectúa una crosvalidación al dataset utilizando K-vecinos como método y devuelve medidas de los resultados como la media o la desviación.
Usamos el método kvecinos con 3 vecinos como parámetro.
Este método particiona el dataset en: datos de training y datos de test, entrena el método sobre los datos de training y después valida el método sobre los datos de test.
El parámetro del número de crossvalidaciones indica el número de particiones que vamos a hacer al dataset y el número de veces que se va a repetir el proceso.
Si el parámetro es N, particionaremos el dataset en N subconjuntos, entrenaremos con N-1 subconjuntos y validaremos el dataset sobre el subconjunto restante repitiendo el proceso N veces.

Esther Garate
Laura de Luis

```
from sklearn.datasets import load_digits
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
misdatos= load_digits ()    #cargo la base de datos en una variable
X=misdatos.data  #creo la matriz X con los datos
Y=misdatos.target #creo la matriz Y con las etiquetas
miKvecinos=KNeighborsClassifier(n_neighbors=3)
from sklearn.model_selection import cross_val_score #importa el modelo cross_val_score
#cross_val_score(estimator, X, y=None, groups=None, scoring=None, cv=None, n_jobs=1,
verbose=0, fit_params=None, pre_dispatch='2*n_jobs')
#Evalúa una puntuación para una cross-validation
   #estimator: el modelo al que implementar fit
   #X: la matriz de los datos en un array
   #Y: las etiquetas en caso de aprendizaje supervisado
   #groups:
   #scoring: una cadena o un puntuador ¿
   #cv: determina la crossvalidación: puede ser un entero (el valor por defecto es 3) un
objeto o un iterable
   #n_jobs: el número de CPU que usa la computación
   #verbose: nivel de verbosidad
   #fit_params : parámetros que se pan al método fit.
   #pre_dispatch: controla el número de trabajos durante una ejecución paralela.
micvs=cross_val_score(miKvecinos,X,Y,cv=10)  #crossvalida 10 veces usando kvecinos
print(micvs)
print("Mean:" + str(np.mean(micvs)))  #saca la media de todas las crossvalidaciones
print("Std: "+ str(np.std(micvs)))  #saca la varianza de todas las crossvalidaciones
```

```
Mean:0.98244994406
Std:0.0161038114221
```

Esther Garate
Laura de Luis

Conclusión

Con el método de CV evitamos sobreajuste ya que el subconjunto de datos que forma el training varía en cada iteración.
Al aplicar el método k-vecinos y 10 particiones el número de errores disminuye considerablemente y la varianza es más óptima.

Gráfica de los resultados

```
#Gráfica con la media de los errores y la desviación dependiendo
#del número de crosvalidaciones que apliquemos y con kvecinos=3
from sklearn.datasets import load_digits
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
misdatos=load_digits()
X=misdatos.data
Y=misdatos.target
miKvecinos=KNeighborsClassifier(n_neighbors=3)
from sklearn.model_selection import cross_val_score
n=0
mean=[]
desv=[]
for n in range(2,10):
    micvs=cross_val_score(miKvecinos,X,Y,cv=n) #crossvalidad n veces usando kvecinos
    print(micvs)
    print("Mean:" + str(np.mean(micvs))) #saca la media de todas las crossvalidaciones
    print("Std: "+ str(np.std(micvs))) #saca la varianza de todas las crossvalidaciones
    mean.append(np.mean(micvs)) #guarda en un array las medias
    desv.append(np.std(micvs)) #guarda en un array las desviaciones
plt.plot(range(2,10),mean, 'b-',label='Num. medio de errores') #dibujamos la gráfica
plt.plot(range(2,10), desv, 'r-',label='Desv. Std de errores') #con una leyenda
plt.legend(loc='upper right')
plt.xlabel('Num CV')
plt.title('Análisis')
plt.ylim(0,1)
plt.style.context('seaborn-whitegrid')
```

Visualizamos la media y desviación dependiendo del número de iteraciones:

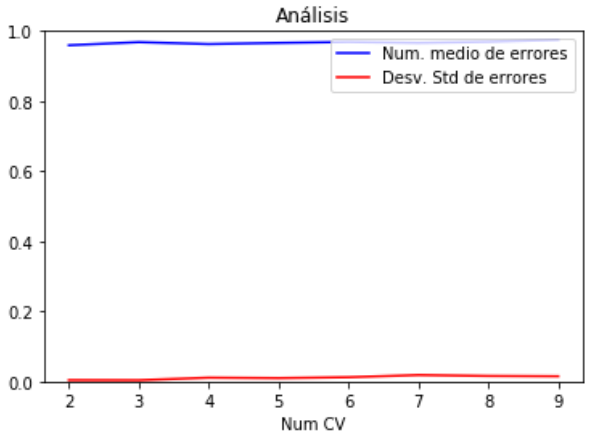

Esther Garate
Laura de Luis

Gráfica comparando Training y Test

Repetimos el proceso aplicando stratiffiedshufflesplit al dataset para que el dataset de training no sea siempre el mismo y predecimos la accuracy sobre los datos de test y sobre los de training.

```
#Repito el proceso 20 veces estratificando el dataset para obtener la curva
misss = StratifiedShuffleSplit(20,0.33)
index = 0
Res = []
Restrain = []
Ytrain = []
Ytest = []
for train_index, test_index in misss.split(X,Y):
    Xtrain = X[train_index,:]
    Xtest = X[test_index,:]
    Ytrain = Y[train_index]
    Ytest = Y[test_index]
    Restrain = cross_val_score(miKvecinos, Xtrain, Ytrain,cv=20)
    Restest = cross_val_score(miKvecinos, Xtest, Ytest,cv=20)
    index = index +1
#Gráfica de las accuracys para Test y Train
arrayx= range(1,21)
plt.plot(arrayx,Restrain, 'r--',label='Accuracy Train')
plt.plot(arrayx,Restest, 'g--',label='Accuracy Test')
plt.axis([0, 20, 0, 1.2])
plt.legend(loc='up right')
plt.xlabel('numero CV')
plt.ylabel('Accuracy')
plt.show()
```

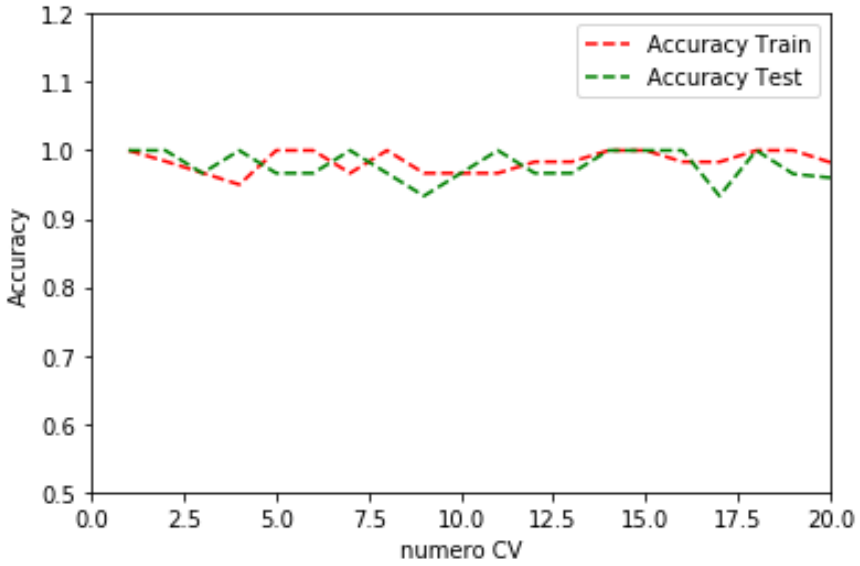

Podemos observar que la accuracy para predecir el Test y el Train no depende del número de crosvalidaciones y es bastante óptimo, aunque el número de cros validaciones sea bajo. Esto es porque el dataset tiene una buena distribución.

Esther Garate
Laura de Luis

KNN3

Aplicación del método GridSearch K-vecinos para obtener distintas accuracys cuando varían los parámetros de modelo de kvecinos. Se crea una rejilla con los resultados de cada iteración

```
from sklearn.datasets import load_digits

from sklearn.neighbors import KNeighborsClassifier

import numpy as np

misdatos= load_digits() #cargo los datos

X=misdatos.data #creo la matriz X

Y=misdatos.target # vector Y de las etiquetas

miKvecinos=KNeighborsClassifier

from sklearn.model_selection import GridSearchCV

#importa el método GridSearchCV hace una busqueda por rejilla.

mi_param_grid={'n_neighbors':[3,5,7,9,11,13,15],'weights':['uniform','distance']} #número de vecinos: valores a,b,c,d de la rejilla

migscv=GridSearchCV(miKvecinos,mi_param_grid,cv=10,verbose=2)

#verbose hace que salga por pantalla lo que va haciendo

migscv.fit(X,Y)

print("migcsc"+ str(migscv))

#Fitting 10 folds for each of 14 candidates, totalling 140 fits 7 (a,,b,c,d,...) (3,5,7,9...* 2 (alfa,beta) uniform distanre

#migscv.best_estimator_

miMejorKvecinos=migscv.best_estimator_ #se escoge la mejor opción de calibración

miMejorKvecinos.fit(X,Y) #el modelo aprende

print("mimejor" +str(miMejorKvecinos)) #se imprime el resultado
```

Esther Garate
Laura de Luis

Resultado
Después de hacer la rejilla el mejor modelo es:

```
print (migscv.best_estimator_)
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
        metric_params=None, n_jobs=1, n_neighbors=3, p=2,
        weights='distance')
```

Y sus medias y varianzas son:

```
print (migscv.grid_scores_)
[mean: 0.97774, std: 0.01594, params: {'n_neighbors': 3, 'weights': 'uniform'},
mean: 0.97830, std: 0.01605, params: {'n_neighbors': 3, 'weights': 'distance'},
mean: 0.97385, std: 0.01655, params: {'n_neighbors': 5, 'weights': 'uniform'},
mean: 0.97385, std: 0.01655, params: {'n_neighbors': 5, 'weights': 'distance'},
mean: 0.96995, std: 0.01919, params: {'n_neighbors': 7, 'weights': 'uniform'},
mean: 0.96995, std: 0.01920, params: {'n_neighbors': 7, 'weights': 'distance'},
mean: 0.96717, std: 0.02008, params: {'n_neighbors': 9, 'weights': 'uniform'},
mean: 0.96995, std: 0.02108, params: {'n_neighbors': 9, 'weights': 'distance'},
mean: 0.96550, std: 0.02123, params: {'n_neighbors': 11, 'weights': 'uniform'},
mean: 0.96772, std: 0.01876, params: {'n_neighbors': 11, 'weights': 'distance'},
mean: 0.96494, std: 0.02244, params: {'n_neighbors': 13, 'weights': 'uniform'},
mean: 0.96550, std: 0.02227, params: {'n_neighbors': 13, 'weights': 'distance'},
mean: 0.96439, std: 0.02147, params: {'n_neighbors': 15, 'weights': 'uniform'},
mean: 0.96605, std: 0.02236, params: {'n_neighbors': 15, 'weights': 'distance'}]
```

Conclusión:
Este método te facilita saber cuál es el mejor ajuste para el modelo que estás utilizando, sin tener que ir probando uno a uno.

Como parámetros pasamos solo los impares para que sea equidistante.

En este caso el mejor método de kvecinos es con los parámetros 3 vecinos y el peso uniforme.

Esther Garate
Laura de Luis

Gráfica con la comparativa de las accuracys para Train y Test

```
#imprimir gráfica de scores train/test
import matplotlib.pyplot as plt
import numpy as np
from sklearn.svm import SVC
from sklearn.model_selection import validation_curve
datacancer = load_breast_cancer()
X= datacancer.data
Y= datacancer.target
estimator=KNeighborsClassifier()
param_range = [1,2,3,4,5,6,7,8,9,10,11,12,13,14,15]

train_scores, test_scores = validation_curve(
  estimator, X, Y, param_name="n_neighbors", param_range=param_range,
   cv=2, scoring="accuracy", n_jobs=1)

train_scores_mean = np.mean(train_scores, axis=1)
train_scores_std = np.std(train_scores, axis=1)
test_scores_mean = np.mean(test_scores, axis=1)
test_scores_std = np.std(test_scores, axis=1)
plt.title("Validation Curve with GS")
plt.xlabel("Kvecinos")
plt.ylabel("Score")
plt.ylim(0.0, 1.1)
plt.xlim(1, 15)
lw = 2
plt.plot(param_range, train_scores_mean, label="Training score",
         color="darkorange", lw=lw)
plt.plot(param_range, test_scores_mean, label="Test score",
         color="navy", lw=lw)
plt.legend(loc="best")
plt.axis([0,15, 0, 1.2])
plt.show()
```

Esther Garate
Laura de Luis

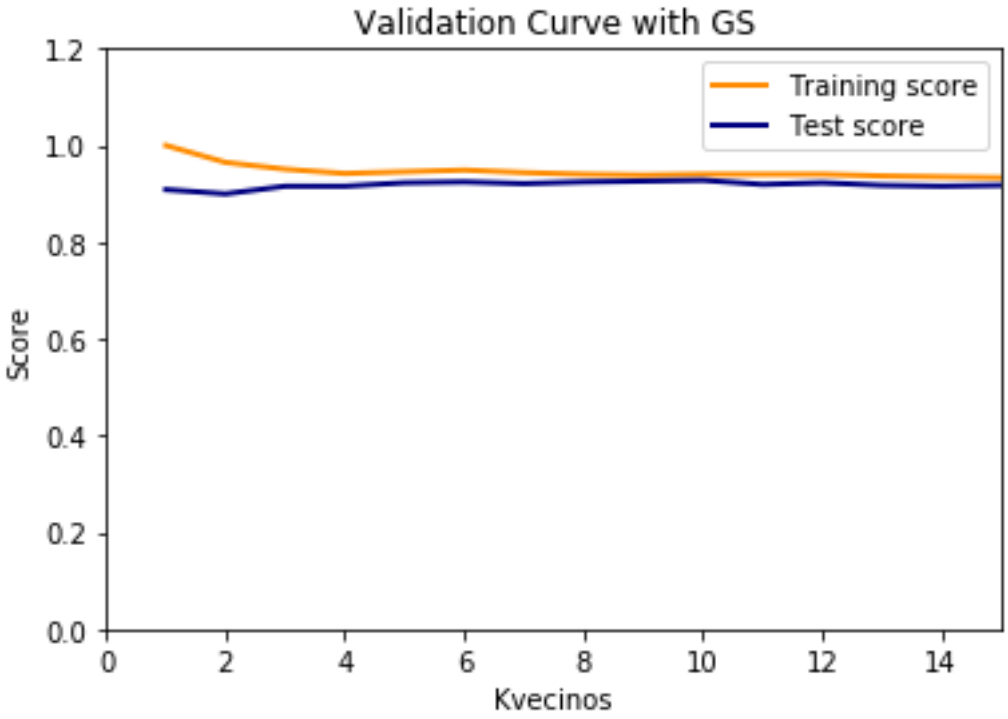

En la gráfica se observa que cuanto mayor es el parámetro kvecinos mas similares son las accuracys obtenidas con Train y Test, lo que significa que la predicción es más ajustada y es un buen modelo para este dataset.
A partir de 3 vecinos la acuracy empieza a ser muy similar para los datos de Test y los de Train siendo un valor bastante óptimo.
kvecinos genera es un buen método para este dataset.

Esther Garate
Laura de Luis

KNN4

Se eliminan características del dataset con la función PCA para poder ilustrar el dataset en dos dimensiones

```
from sklearn.datasets import load_iris
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import StratifiedShuffleSplit
from matplotlib import pyplot as plt
from sklearn.decomposition import PCA
import numpy as np
misdatos=load_iris()
X=misdatos.data
Y=misdatos.target
miPCA=PCA(n_components=2)
#eliminamos columnas de "features" para poder pintar una proyección
#por componentes principales pongo 2 que es igual que el num de columnas transformadas
X_PCA=miPCA.fit_transform(X)
#has proyectado todo manteniendo la máxima varianza
#eliminas la varianza cero porque no te aporta nada nuevo
plt. scatter(X_PCA[:,0],X_PCA[:,1],s=100,c=Y)
plt.show()
#Vamos a pintar las etiquetas con s=100, c=Y
```

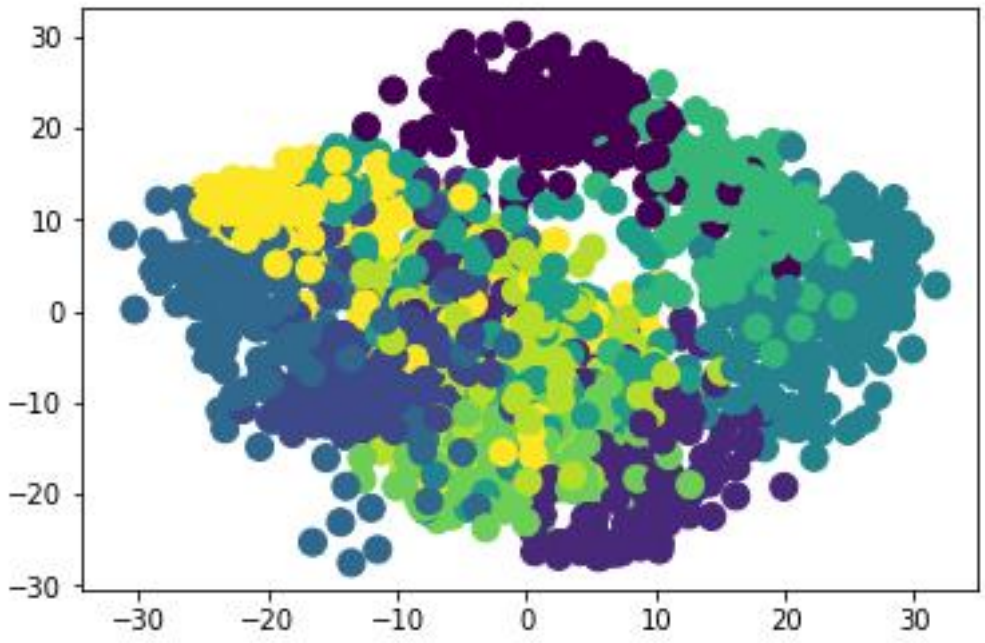

Esther Garate
Laura de Luis

Gráfica de Covarianza

```
#gráfica covarianza
from sklearn.decomposition  import  PCA
covar_matrix = PCA(n_components  = 30) #we have 30 features
covar_matrix.fit(X)
variance = covar_matrix.explained_variance_ratio_  #calculate variance ratios

var=np.cumsum(np.round(covar_matrix.explained_variance_ratio_,  decimals=3)*100)
print(var)
plt.ylabel('%  Variance Explained')
plt.xlabel('# of Features')
plt.title('PCA  Analysis')
#plt.ylim(30,100.5)
plt.style.context('seaborn-whitegrid')

plt.plot(var)
```

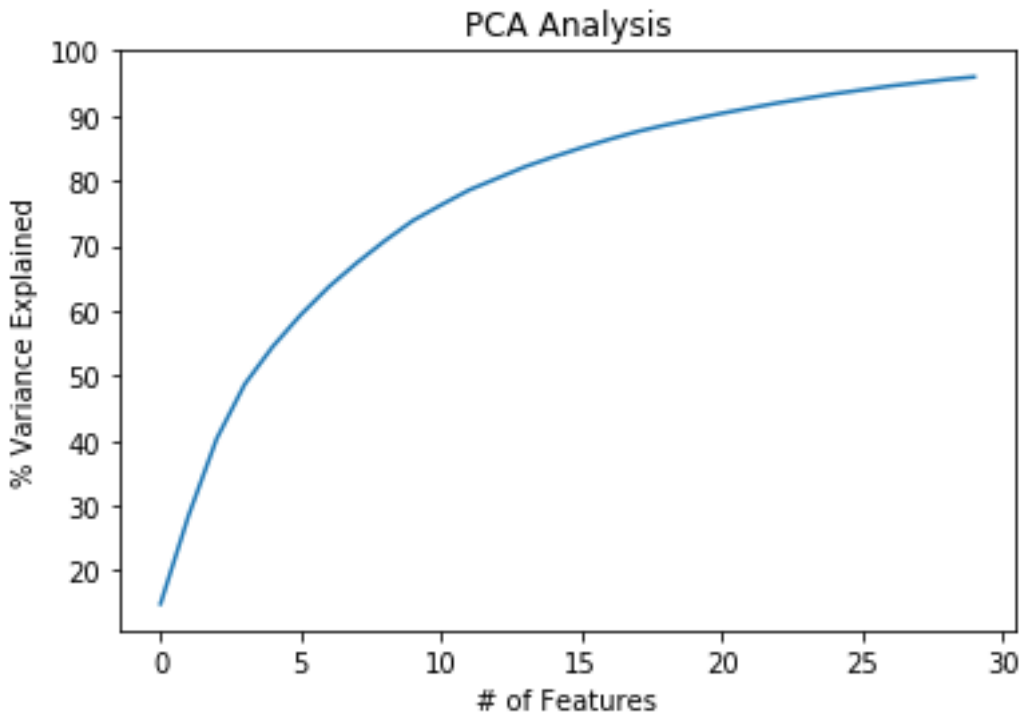

Si cogemos sólo dos features para poder plotear la proyección estamos perdiendo mucha información ya que la covarianza es muy baja, alrededor de 20. La ilustración de este dataset con dos variables no sería significativa.

Esther Garate
Laura de Luis

4) Consulta la documentación de la librería Scikit-learn y configura el script de validación automatizada (#3) para que la función GridSearchCV() utilice validación leave-one-out en lugar de k-fold. Describe qué conclusiones pueden extraerse a partir de los scores medios de cross-validación y el de test utilizando un modelo por k-vecinos con k optimizada.

Usamos el Gridsearch con crossvalidación = LeaveOneOut y con crossvalidacion = 10 para así comparar los resultados de los dos métodos. Usamos kvecinos impares para evitar empates.

CÓDIGO

```
from sklearn.datasets import load_digits
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
from  sklearn.model_selection  import LeaveOneOut
from sklearn.metrics import accuracy_score
from sklearn.model_selection  import StratifiedShuffleSplit
datacancer = load_digits()

X= datacancer.data
Y= datacancer.target

################################  LEAVE ONE OUT ####################

#Dividimos el dataset en Train(2/3) y test(1/3)
misss = StratifiedShuffleSplit(1,  0.33)
index=0
for train_index, test_index in misss.split(X, Y):
    Xtrain=X[train_index,:]
    Xtest=X[test_index,:]
    Ytrain=Y[train_index]
    Ytest=Y[test_index]
    index=index+1

#Aplicamos el metodo Grid Search para el elegir el mejor modelo para nuestro data set
#Con CV de leaveOneOut, que es equivalente a hacer una CV con tanatas k-folds como ejemplos
#tiene nuestro dataset, en este caso 569 ejemplos.
miKvecinos=KNeighborsClassifier()

from sklearn.model_selection  import GridSearchCV
mi_param_grid={'n_neighbors':[3,4,5,6,7,8,9,10,11],  'weights':['uniform','distance']}
```

Esther Garate
Laura de Luis

```
        migscv=GridSearchCV(miKvecinos,mi_param_grid,cv=LeaveOneOut(),verbose=2)
        migscv.fit(Xtrain,Ytrain)
        miMejorKvecinosLOO=migscv.best_estimator_
        miMejorKvecinosLOO.fit(Xtrain,Ytrain)
        Ypred = miMejorKvecinosLOO.predict(Xtest)
        accuracy_score(Ytest,  Ypred

#Repito el proceso de stratificacion 20 veces, entreno con mi mejor modelo de LOO
# y saco las accuracys de las 2¶0 iteraciones con Xtest y con Xtrain
        misss = StratifiedShuffleSplit(20,0.33)
        index = 0
        ResLOO = []
        ResLOOtrain = []
        for train_index, test_index in misss.split(X,Y):
            Xtrain = X[train_index,:]
            Xtest = X[test_index,:]
            Ytrain = Y[train_index]
            Ytest = Y[test_index]
            miMejorKvecinosLOO.fit(Xtrain,Ytrain)
            Ypred = miMejorKvecinosLOO.predict(Xtest)
            Ypredtrain = miMejorKvecinosLOO.predict(Xtrain)
            print (accuracy_score(Ytest,  Ypred))
            ResLOO.append(accuracy_score(Ytest,  Ypred))
            ResLOOtrain.append(accuracy_score(Ytrain,  Ypredtrain))
            index = index +1
print ("Accuracy de LOO: " + str(ResLOO))
print ("Media LOO:" + str(np.mean(ResLOO)))
print ("DevLOO:" + str(np.std(ResLOO)))
print ("Accuracy de LOOtrain: " + str(ResLOOtrain))
print ("Media LOOtrain:" + str(np.mean(ResLOOtrain)))
print ("DevLOOtrain:" + str(np.std(ResLOOtrain)))


#Gráfica con la comparacion de accuracy para Ytest e Ytrain con el mejor modelo
#Y con LOO
plt.plot([3, 3], [np.mean(ResLOO),np.mean(ResLOOtrain)  ])
plt.axis([0, 10, 0.9, 1])

plt.show()

arrayx= range(1,21)
plt.plot(arrayx,ResLOO,  'r--', arrayx,ResLOOtrain,  'g--')
plt.axis([0, 20, 0.8, 1])

plt.xlabel('numero iteracion')
plt.ylabel('Accuracy')
plt.show()
```

Esther Garate
Laura de Luis

```
################  CROSS VALIDATION ########################33
#Dividimos el dataset en Train(2/3) y test(1/3)
misss = StratifiedShuffleSplit(1,  0.33)
#GridSearch Con  10 CV
migscv=GridSearchCV(miKvecinos,mi_param_grid,cv=10,verbose=2)
migscv.fit(Xtrain,Ytrain)
#Mejor estimador
print (migscv.best_estimator_)
#Media y varianza para todos los modelos
print (migscv.grid_scores_)
miMejorKvecinosCV=migscv.best_estimator_
miMejorKvecinosCV.fit(Xtrain,Ytrain)
Ypred = miMejorKvecinosCV.predict(Xtest)
accuracy_score(Ytest, Ypred)
#Repito el proceso de stratificacion 20 veces con mi mejor modelo de CV
index = 0
ResCV = []
ResCVtrain = []
misss = StratifiedShuffleSplit(20,0.33)
for train_index, test_index in misss.split(X,Y):
   Xtrain = X[train_index,:]
   Xtest = X[test_index,:]
   Ytrain = Y[train_index]
   Ytest = Y[test_index]
   miMejorKvecinosCV.fit(Xtrain,Ytrain)
   Ypred = miMejorKvecinosCV.predict(Xtest)
   Ypredtrain = miMejorKvecinosCV.predict(Xtrain)
   print (accuracy_score(Ytest, Ypred))
   print (accuracy_score(Ytrain, Ypredtrain))
   ResCV.append(accuracy_score(Ytest,  Ypred))
   ResCVtrain.append(accuracy_score(Ytrain,  Ypredtrain))
   index = index +1

#Resultados
print ("Accuracy de CV: " + str(ResCV))
print ("Media:" + str(np.mean(ResCV)))
print ("Dev:" + str(np.std(ResCV)))
 print ("Accuracy de CV train: " + str(ResCVtrain))
print ("Media:" + str(np.mean(ResCVtrain)))
print ("Dev:" + str(np.std(ResCVtrain)))
#Pintar gráfica con las curvas de la accuracy para train y para test
import matplotlib.pyplot as plt
plt.plot([11, 11], [np.mean(ResCV),np.mean(ResCVtrain)  ])
plt.plot([3, 3], [np.mean(ResLOO),np.mean(ResLOOtrain)  ])
 plt.axis([0, 12, 0.8, 1])
plt.show()
```

Esther Garate
Laura de Luis

Con leave one out

Mi mejor modelo

```
print (migscv.best_estimator_)
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
          metric_params=None, n_jobs=1, n_neighbors=4, p=2,
          weights='distance')
```

Scores de todos los modelos:

```
print (migscv.grid_scores_)
[mean: 0.98504, std: 0.12140, params: {'n_neighbors': 3, 'weights': 'uniform'},
mean: 0.98587, std: 0.11803, params: {'n_neighbors': 3, 'weights': 'distance'},
mean: 0.98254, std: 0.13096, params: {'n_neighbors': 4, 'weights': 'uniform'},
mean: 0.98670, std: 0.11456, params: {'n_neighbors': 4, 'weights': 'distance'},
mean: 0.98504, std: 0.12140, params: {'n_neighbors': 5, 'weights': 'uniform'},
mean: 0.98587, std: 0.11803, params: {'n_neighbors': 5, 'weights': 'distance'},
mean: 0.98005, std: 0.13983, params: {'n_neighbors': 6, 'weights': 'uniform'},
mean: 0.98670, std: 0.11456, params: {'n_neighbors': 6, 'weights': 'distance'},
mean: 0.98005, std: 0.13983, params: {'n_neighbors': 7, 'weights': 'uniform'},
mean: 0.98337, std: 0.12786, params: {'n_neighbors': 7, 'weights': 'distance'},
mean: 0.98005, std: 0.13983, params: {'n_neighbors': 8, 'weights': 'uniform'},
mean: 0.98254, std: 0.13096, params: {'n_neighbors': 8, 'weights': 'distance'},
mean: 0.97922, std: 0.14265, params: {'n_neighbors': 9, 'weights': 'uniform'},
mean: 0.98088, std: 0.13694, params: {'n_neighbors': 9, 'weights': 'distance'},
mean: 0.97672, std: 0.15078, params: {'n_neighbors': 10, 'weights': 'uniform'},
mean: 0.98088, std: 0.13694, params: {'n_neighbors': 10, 'weights': 'distance'},
mean: 0.97672, std: 0.15078, params: {'n_neighbors': 11, 'weights': 'uniform'},
mean: 0.97922, std: 0.14265, params: {'n_neighbors': 11, 'weights': 'distance'}]
```

Score del mejor modelo:

0.99158249158249157

Aplicamos el mejor modelo a 20 muestras distintas de Xtrain y de Xtest con el shuffledSplit y obtenemos los scores:

Resultados prediciendo con Ytest

Accuracys

Accuracy de LOO: [[0.98989898989898994, 0.98148148148148151, 0.98653198653198648, 0.98484848484848486, 0.99158249158249157, 0.97643097643097643, 0.98821548821548821, 0.98316498316498313, 0.98989898989898994, 0.98821548821548821, 0.98148148148148151, 0.98821548821548821, 0.9932659932659933, 0.98316498316498313, 0.98653198653198648, 0.97643097643097643, 0.98653198653198648, 0.99158249158249157, 0.97306397306397308, 0.98316498316498313]]

Media

Media LOO: 0.985185185185

Desviacion

DevLOO: 0.00531304169632

Resultados prediciendo con Ytrain

Accuracys

Accuracy de LOOtrain: [1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0]

Media

Media LOOtrain: 1.0

Desviacion

DevLOOtrain:0.0

Esther Garate
Laura de Luis

Con CV

Mi mejor modelo

```
print (migscv.best_estimator_)
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
          metric_params=None, n_jobs=1, n_neighbors=3, p=2,
          weights='uniform')
```

Scores de todos los modelos:

```
print (migscv.grid_scores_)
[mean: 0.98753, std: 0.01006, params: {'n_neighbors': 3, 'weights': 'uniform'},
mean: 0.98753, std: 0.01006, params: {'n_neighbors': 3, 'weights': 'distance'},
mean: 0.98005, std: 0.01287, params: {'n_neighbors': 4, 'weights': 'uniform'},
mean: 0.98670, std: 0.01056, params: {'n_neighbors': 4, 'weights': 'distance'},
mean: 0.98504, std: 0.01271, params: {'n_neighbors': 5, 'weights': 'uniform'},
mean: 0.98587, std: 0.01110, params: {'n_neighbors': 5, 'weights': 'distance'},
mean: 0.97839, std: 0.01449, params: {'n_neighbors': 6, 'weights': 'uniform'},
mean: 0.98421, std: 0.01235, params: {'n_neighbors': 6, 'weights': 'distance'},
mean: 0.97672, std: 0.01423, params: {'n_neighbors': 7, 'weights': 'uniform'},
mean: 0.97839, std: 0.01441, params: {'n_neighbors': 7, 'weights': 'distance'},
mean: 0.97589, std: 0.01084, params: {'n_neighbors': 8, 'weights': 'uniform'},
mean: 0.97839, std: 0.01347, params: {'n_neighbors': 8, 'weights': 'distance'},
mean: 0.97506, std: 0.01292, params: {'n_neighbors': 9, 'weights': 'uniform'},
mean: 0.97756, std: 0.01351, params: {'n_neighbors': 9, 'weights': 'distance'},
mean: 0.97340, std: 0.01049, params: {'n_neighbors': 10, 'weights': 'uniform'},
mean: 0.97756, std: 0.01340, params: {'n_neighbors': 10, 'weights': 'distance'},
mean: 0.97257, std: 0.01186, params: {'n_neighbors': 11, 'weights': 'uniform'},
mean: 0.97839, std: 0.01002, params: {'n_neighbors': 11, 'weights': 'distance'}]
```

Score del mejor modelo:

0.98653198653198648

Aplicamos el mejor modelo a 20 muestras distintas de Xtrain y de Xtest con el shuffledSplit y obtenemos los scores:

Resultados prediciendo con Ytest

Accuracys

```
[[0.98821548821548821, 0.98653198653198648, 0.99158249158249157,
0.98316498316498313, 0.98484848484848486, 0.98989898989898994,
0.98316498316498313, 0.98653198653198648, 0.98484848484848486,
0.97979797979797978, 0.98821548821548821, 0.98821548821548821,
0.99158249158249157, 0.98148148148148151, 0.98989898989898994,
0.97306397306397308, 0.98989898989898994, 0.98316498316498313,
0.98653198653198648, 0.99158249158249157]]
```

Media

Media: 0.986111111111

Desviacion

Dev: 0.00451338606682

Resultados prediciendo con Ytrain

Accuracys

```
0.99501246882793015, 0.9900249376558603, 0.9908561928512053,
0.99418121363258516, 0.99251870324189528, 0.98919368246051542,
0.99334995843724028, 0.99251870324189528, 0.99251870324189528,
0.99584372402327515, 0.99251870324189528, 0.99251870324189528,
0.99251870324189528, 0.99334995843724028, 0.9908561928512053,
0.99418121363258516, 0.99418121363258516, 0.99168744804655029,
0.99334995843724028, 0.99501246882793015]
```

Media

Media: 0.99280964256

Desviacion

Dev: 0.00166821548133

Esther Garate
Laura de Luis

GRÁFICAS

CODIGO

```
#Gráfica con la comparación de accuracy para Ytest e Ytrain con el mejor modelo de LOO
plt.plot([3, 3], [np.mean(ResLOO),np.mean(ResLOOtrain)  ])
plt.axis([0, 10, 0.9, 1])
plt.show()
arrayx= range(1,21)
plt.plot(arrayx,ResLOO,  'r--', label = 'Test')
plt.plot(arrayx,ResLOOtrain,  'g--', label='Train')
plt.axis([0, 20, 0.8, 1.1])
plt.legend(loc='downer  right')
plt.xlabel('numero  iteracion')
plt.ylabel('Accuracy')
plt.show()

#Gráfica con la comparación de accuracy para Ytest e Ytrain con el mejor modelo de CV
plt.plot([3, 3], [np.mean(ResCV),np.mean(ResCVtrain)  ])
plt.axis([0, 10, 0.9, 1])
plt.show()
arrayx= range(1,21)
plt.plot(arrayx,ResCV,  'r--', label = 'Test')
plt.plot( arrayx,ResCVtrain, 'g--', label = 'Train')
plt.axis([0, 20, 0.8, 1.1])
plt.legend(loc='downer  right')
plt.xlabel('numero  iteracion')
plt.ylabel('Accuracy')
plt.show()


#Pintar gráfica con las curvas de la accuracy para train y para test
import matplotlib.pyplot as plt

plt.plot([11, 11], [np.mean(ResCV),np.mean(ResCVtrain)]  ,label='CV' )
plt.plot([3, 3], [np.mean(ResLOO),np.mean(ResLOOtrain)  ], label = 'LeaveOneOut')
 plt.axis([0, 12, 0.9, 1])
plt.legend(loc='downer  right')
plt.show()
```

Esther Garate
Laura de Luis

Gráfica con las “accuracys” obtenidas al aplicar el mejor modelo de LeaveOneOut a 20 dataset barajeados con kvecinos =3

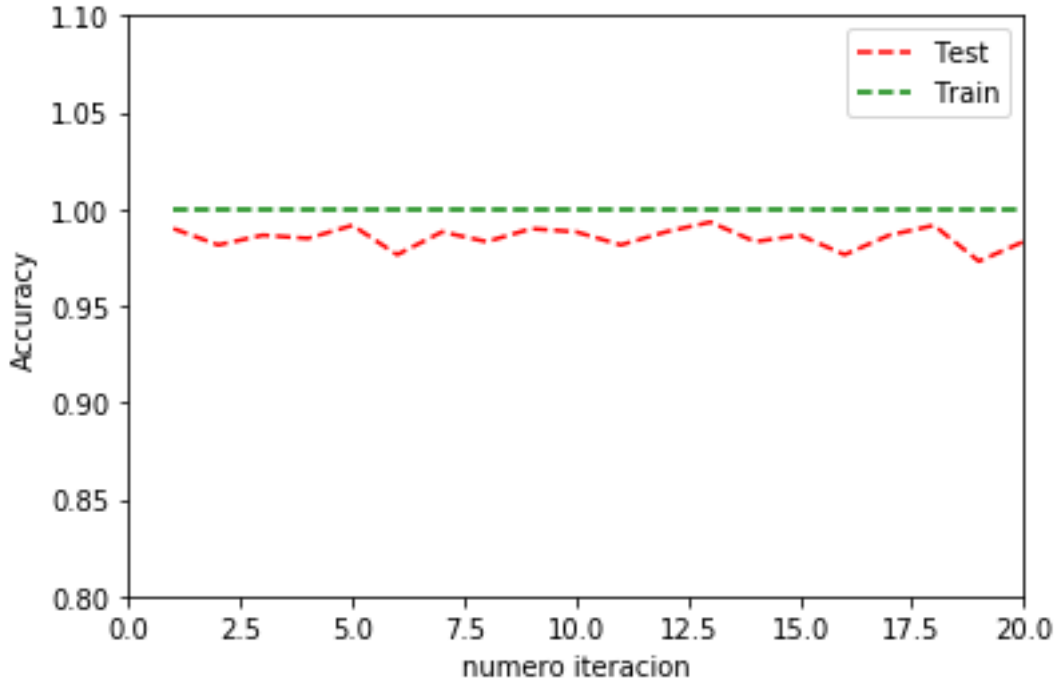

Gráfica con las “accuracys” obtenidas al aplicar el mejor modelo de CV a 20 dataset barajeados con kvecinos =3

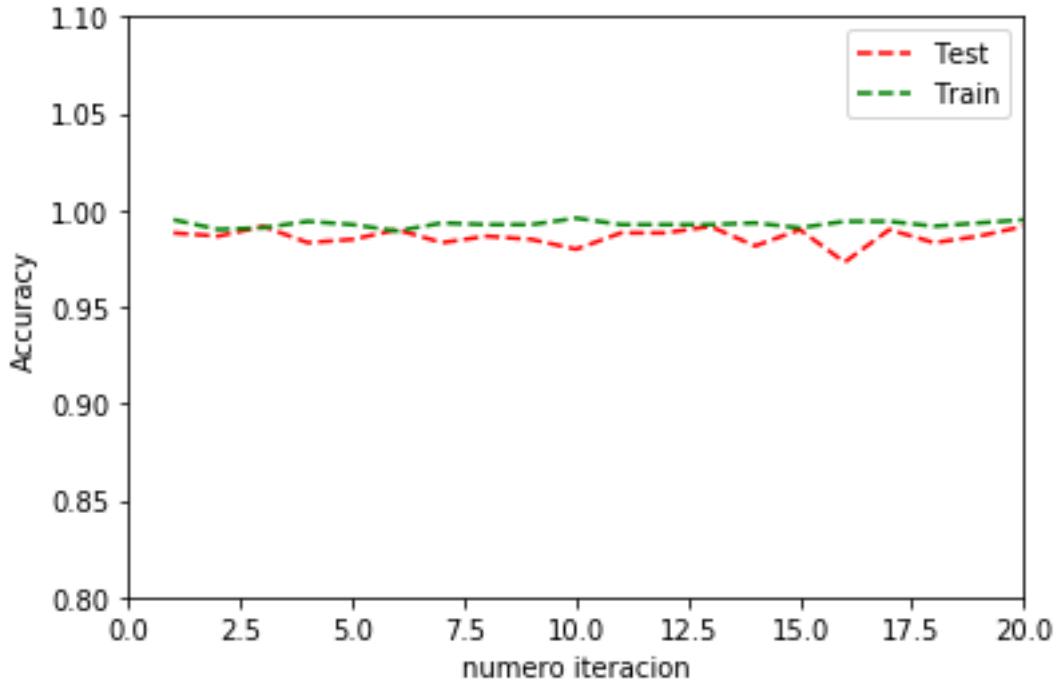

Esther Garate
Laura de Luis

Comparando estas dos gráficas: El método de LOO para los datos de training tiene una accuracy de 1 y desviación de cero.
En este método el subconjunto de training tiene una cardinalidad de (n-samples -1), por lo que al predecir luego el target de training la accuracy es siempre 1, siempre acierta ya que está muy bien entrenado.
Con el método de CV la accuracy de LOO y de CV es bastante similar, el modelo ajusta bien.
Conclusión: cuanto mayor es el subconjunto de datos de training mayor es la accuracy de training.

Gráfica con la comparación de las medias de las accuracys obtenidas al aplicar el mejor modelo de LeaveOneOut a 20 dataset shuffleados con kvecinos = 3.

Gráfica que compara las medias de las accuracys obtenidas para los dos métodos

Punto 11 = CV
Punto 3 = Leave One Out

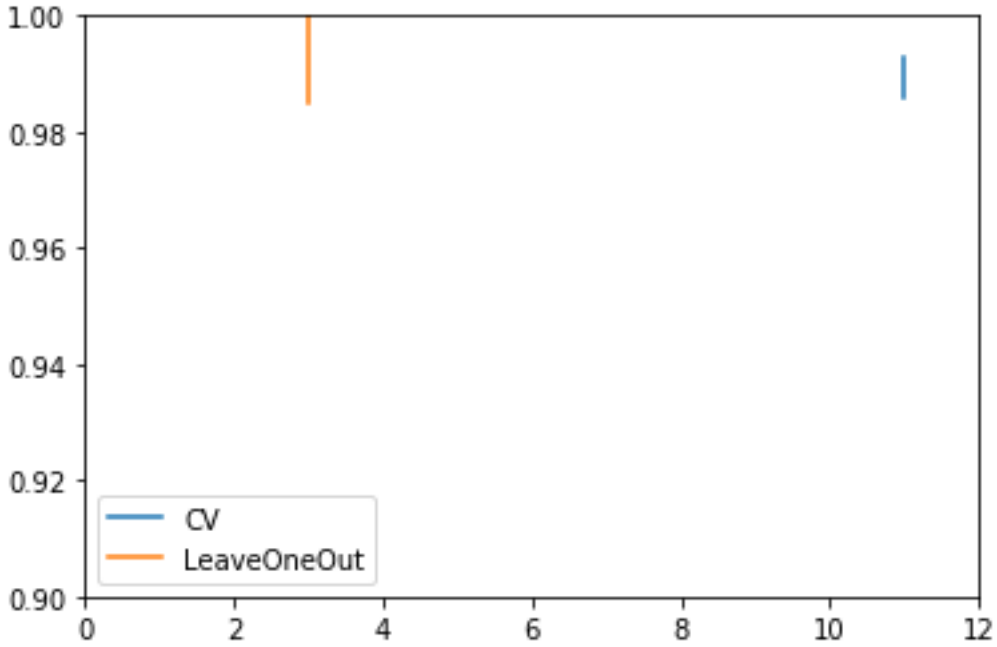

CONCLUSIONES

- Para este dataset el método LeaveOneOut tienes un coste computacional muy elevado, tarda más de media hora en hacer el GridSearch ya que son muchas iteraciones. La validación leave-one-out recorre todo el dataset haciendo cros validación de un ejemplo con todos los demás, es como hacer un kfold con tantas particiones como ejemplos tienes la muestra. El gasto computacional al ejecutarlo es más elevado que en el Kfold con 10 folds ya que el número de iteraciones es mucho más elevado con LeaveOneOut.

- En los dos casos la accuracy se mantiene bastante constante por lo que ambos modelos son estables y consistentes. Es decir, el mejor kvecinos en cada forma de crosvalidar da un buen resultado sobre la muestra.

- Comparando los dos métodos el de CV es más óptimo ya que tiene menor gasto computacional y la accuracy es mejor.

5) Razona si es necesario estratificar el proceso de cross-validación analizando la distribución de muestras por clase.

Estratificar es el proceso de subdividir el dataset en grupos homogéneos antes de coger las muestras. El proceso consiste en ordenar las muestras de manera que la parte del dataset seleccionada para entrenar tiene una representación homogénea de todas las muestras o que, si estas no están balanceadas y se quiere dar relevancia a las minoritarias, se incluyan en mayor medida.
En el caso del dataset de digits se puede ver que el número de labels de cada tipo es similar:

```
import matplotlib.pyplot as plt
print('unos de las etiquetas' + str(sum(Y==0)))
Y0=sum(Y==0)
Y1=sum(Y==1)
Y2=sum(Y==2)
Y3=sum(Y==3)
Y4=sum(Y==4)
Y5=sum(Y==5)
Y6=sum(Y==6)
Y7=sum(Y==7)
Y8=sum(Y==8)
Y9=sum(Y==9)

labels = '0','1', '2', '3', '4','5','6','7','8','9'
sizes = [Y0, Y1, Y2,Y3,Y4,Y5,Y6,Y7,Y8,Y9]
explode = (0, 0.1, 0, 0,0,0,0,0,0,0)

fig1, ax1 = plt.subplots()
ax1.pie(sizes, explode=explode, labels=labels, autopct='%1.1f%%',
        shadow=True, startangle=90)
ax1.axis('equal')

plt.show()
```

Esther Garate
Laura de Luis

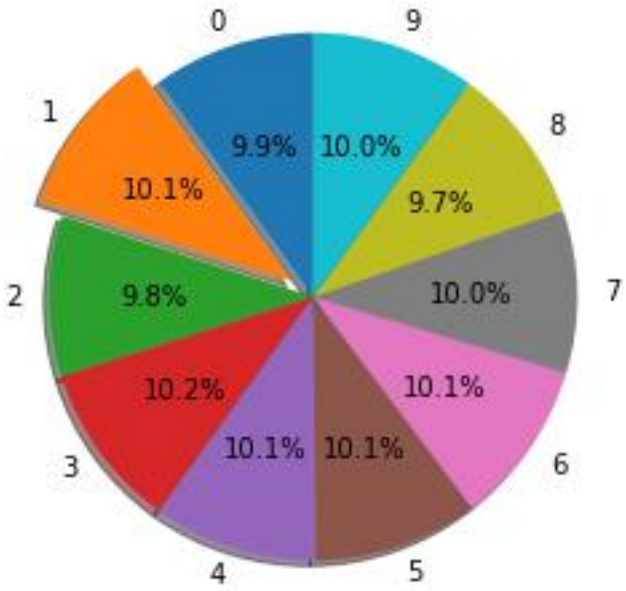

Si ploteamos las 100 primeras labels para ver su distribución obtenemos esta gráfica:

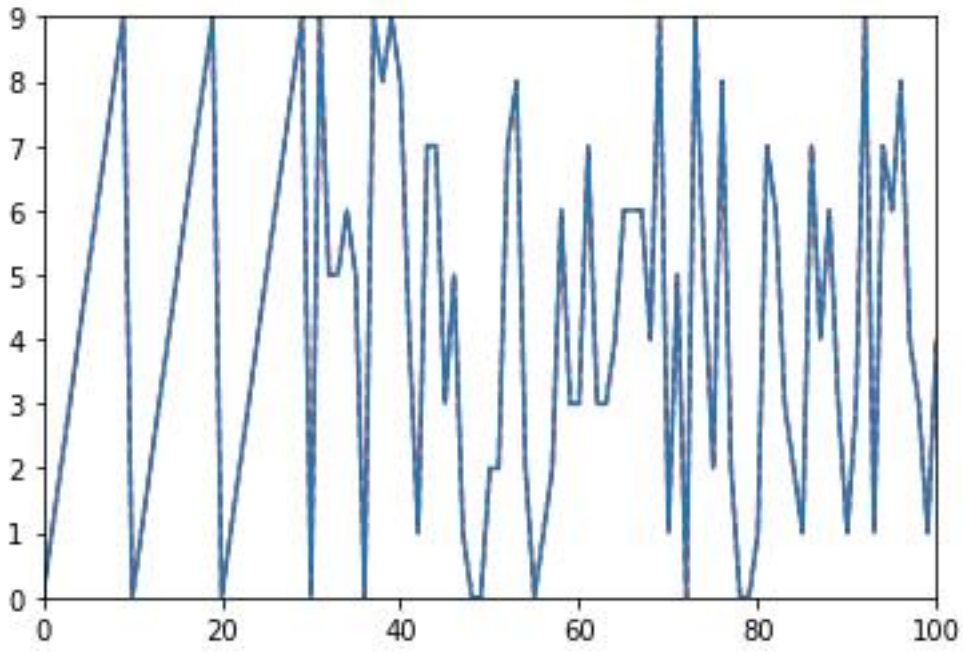

Parece que las “labels” están bastante distribuidas dentro del dataset.

Esther Garate
Laura de Luis

6) Introduce en el proceso de cross-validación el ajuste de los pesos de la métrica de distancia entre muestras de acuerdo al parámetro "weights" del modelo en scikit-learn: Calcula y computa la ganancia/pérdida en desempeño del modelo cuando los pesos de la métrica de distancia son afinados dentro de la validación cruzada respecto al caso visto en clase (ajuste único de K)

```
from sklearn.datasets import load_digits
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
from sklearn.metrics import accuracy_score

data = load_digits()

X= data.data
Y= data.target
#Dividimos el dataset en Train(2/3) y test(1/3)
misss = StratifiedShuffleSplit(1, 0.33)


for trai_index, test_index in misss.split(X,Y):
    Xtrain = X[train_index,:]
    Xtest = X[test_index,:]
    Ytrain = Y[train_index]
    Ytest = Y[test_index]
    index = index +1

#comparo con GridSearch uniform/distance
mi_param_grid={'n_neighbors':[3], 'weights':['uniform','distance']}
migscv=GridSearchCV(miKvecinos,mi_param_grid,cv=10,verbose=2)
migscv.fit(Xtrain,Ytrain)

#Mejor estimador
print (migscv.best_estimator_)
#Media y varianza para todos los modelos
print (migscv.grid_scores_)

#Repito el proceso de stratificacion 20 veces
# y saco las accuracys de las 20 iteraciones para peso uniforme y distancia
misss = StratifiedShuffleSplit(20,0.33)
index = 0
ASU = []
ASD = []
```

Esther Garate
Laura de Luis

```
for train_index, test_index in misss.split(X,Y):
    Xtrain = X[train_index,:]
    Xtest = X[test_index,:]
    Ytrain = Y[train_index]
    Ytest = Y[test_index]
    miKvecinos = KNeighborsClassifier(n_neighbors=3, weights = 'uniform')
    miKvecinos.fit(Xtrain,Ytrain)
    Ypred = miKvecinos.predict(Xtest)
    ASU.append(accuracy_score(Ytest, Ypred))
    miKvecinos = KNeighborsClassifier(n_neighbors=3, weights = 'distance')
    miKvecinos.fit(Xtrain,Ytrain)
    Ypred = miKvecinos.predict(Xtest)
    accuracy_score(Ytest, Ypred)
    ASD.append(accuracy_score(Ytest, Ypred))
    index = index +1

print (ASU)
print (ASD)

print ("Accuracy de unifrom: " + str(ASU))
print ("Media uniform:" + str(np.mean(ASU)))
print ("Dev uniform:" + str(np.std(ASU)))
print ("Accuracy de distance: " + str(ASD))
print ("Media distance:" + str(np.mean(ASD)))
print ("Dev distance:" + str(np.std(ASD))
```

RESULTADO

```
best_estimator_
        KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                metric_params=None, n_jobs=1, n_neighbors=3, p=2,
                weights='distance')
```

Weigth = uniform

Accuracy de uniform: [0.99158249158249157, 0.98148148148148151,
0.98821548821548821, 0.98821548821548821, 0.98989898989898994,
0.98316498316498313, 0.98316498316498313, 0.98484848484848486,
0.98148148148148151, 0.98316498316498313, 0.99158249158249157,
0.99158249158249157, 0.99158249158249157, 0.98653198653198648,
0.97643097643097643, 0.98989898989898994, 0.98653198653198648,
0.97643097643097643, 0.98653198653198648, 0.98989898989898994
Media uniform: 0.986111111111
Dev uniform: 0.00463727559624

Esther Garate
Laura de Luis

RESULTADO

Weigth = distance

Accuracy de distance: [0.99158249158249157, 0.98148148148148151, 0.98821548821548821, 0.98653198653198648, 0.99158249158249157, 0.98316498316498313, 0.98484848484848486, 0.98484848484848486, 0.98148148148148151, 0.98484848484848486, 0.99494949494949492, 0.99158249158249157, 0.9932659932659933, 0.98653198653198648, 0.97643097643097643, 0.98989898989898994, 0.98653198653198648, 0.97811447811447816, 0.98484848484848486, 0.98989898989898994]
Media distance: 0.986531986532
Dev distance: 0.00482081517282

CONCLUSIÓN

Al hacer el Grid search el mejor estimador con 3 kvecinos es con el peso de distancia.
Repetimos el proceso 20 veces con el dataset barajeado para obtener "accuracys" con distintos subconjuntos del dataset para los dos tipos de peso.
La media de la "acuracy" es muy buena, el método modela bien el dataset.
Esto significa que al darle mayor influencia a los puntos cercanos el resultado es óptimo, es decir que los puntos más cercanos a uno dado tienen más influencia que el resto.

Esther Garate
Laura de Luis

7) Siguiendo la misma aproximación del último apartado, introduce el tipo de métrica de distancia (parámetro "metric") dentro del proceso de validación cruzada. Evalúa los resultados y las ganancias/pérdidas de capacidad de generalización del modelo.

Los tipos de métricas son los siguientes:

Metrics intended for real-valued vector spaces:

identifier	class name	args	distance function
"euclidean"	EuclideanDistance	•	`sqrt(sum((x - y)^2))`
"manhattan"	ManhattanDistance	•	`sum(|x - y|)`
"chebyshev"	ChebyshevDistance	•	`max(|x - y|)`
"minkowski"	MinkowskiDistance	p	`sum(|x - y|^p)^(1/p)`
"wminkowski"	WMinkowskiDistance	p, w	`sum(w * |x - y|^p)^(1/p)`
"seuclidean"	SEuclideanDistance	V	`sqrt(sum((x - y)^2 / V))`
"mahalanobis"	MahalanobisDistance	V or VI	`sqrt((x - y)' V^-1 (x - y))`

Comparamos las cuatro primeras.

```
#Valid metrics are ['euclidean', 'l2', 'l1', 'manhattan', 'cityblock',
#                'braycurtis', 'canberra', 'chebyshev', 'correlation',
#                'cosine', 'dice', 'hamming', 'jaccard', 'kulsinski',
#                'mahalanobis', 'matching', 'minkowski', 'rogerstanimoto',
#                'russellrao', 'seuclidean', 'sokalmichener', 'sokalsneath',
#                'sqeuclidean', 'yule', 'wminkowski'], or 'precomputed', or a
#                callable

        from sklearn.datasets import load_digits
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.model_selection import StratifiedShuffleSplit
        from sklearn.model_selection import GridSearchCV
        from sklearn.model_selection import cross_val_score

        import numpy as np
        from sklearn.metrics import accuracy_score
        data = load_digits()
        X= data.data
        Y= data.target
```

Esther Garate
Laura de Luis

```
#dividimos el Dataset en Xtrain y Xtest
        misss = StratifiedShuffleSplit(1, 0.33)

        miKvecinos=KNeighborsClassifier()

#aplicamos el metodo GridSearch para hayar la mejor metrica para nuestro modelo con K-vecinos = 5
        mi_param_grid={'n_neighbors':[5], 'metric' : ["euclidean", "manhattan",
        "chebyshev", "minkowski", "l1", "l2", "cityblock", 'hamming', 'jaccard', 'kulsinski']
        }
        migscv=GridSearchCV(miKvecinos,mi_param_grid,cv=2,verbose=2)
        migscv.fit(X,Y)
        print (migscv.best_estimator_)
        print (migscv.cv_results_)

        miMejorKvecinos=migscv.best_estimator_
        miMejorKvecinos.fit(Xtrain,Ytrain)
        Ypred = miMejorKvecinos.predict(Xtest)
        accuracy_score(Ytest, Ypred)

        print (migscv.grid_scores_)
        print (migscv.best_score_)
        #Repito el proceso de stratificacion 20 veces, entreno con mi mejor con la
        distancia manhattan
# y saco las accuracys de las 2¶0 iteraciones con Xtest y con Xtrain
        misss = StratifiedShuffleSplit(20,0.33)
        index = 0
        Res = []
        Restrain = []
        for train_index, test_index in misss.split(X,Y):
            Xtrain = X[train_index,:]
            Xtest = X[test_index,:]
            Ytrain = Y[train_index]
            Ytest = Y[test_index]
            miMejorKvecinos.fit(Xtrain,Ytrain)
            Ypred = miMejorKvecinos.predict(Xtest)
            Ypredtrain = miMejorKvecinos.predict(Xtrain)
            print (accuracy_score(Ytest, Ypred))
            Res.append(accuracy_score(Ytest, Ypred))
            Restrain.append(accuracy_score(Ytrain, Ypredtrain))
            index = index +1

#Accuracis prediciendo con Ytest
        print (Res)
#Accuracis prediciendo con Ytrain
        print (Restrain)
```

Esther Garate
Laura de Luis

```
print ("Accuracy : " + str(Res))
print ("Media:" + str(np.mean(Res)))
print ("Dev:" + str(np.std(Res)))

print ("Accuracy de train: " + str(Restrain))
print ("Media train:" + str(np.mean(Restrain)))
print ("Devtrain:" + str(np.std(Restrain)))

plt.plot([5, 5], [np.mean(Res),np.mean(Restrain) ])
plt.axis([0, 10, 0.8, 1])

plt.show()
```

Mi mejor estimador

```
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='euclidean',
          metric_params=None, n_jobs=1, n_neighbors=5, p=2,
          weights='uniform')
```

Grid scores

```
print (migscv.grid_scores_)
[mean: 0.95270, std: 0.00154, params: {'n_neighbors': 5, 'metric': 'euclidean'},
mean: 0.94157, std: 0.00373, params: {'n_neighbors': 5, 'metric': 'manhattan'},
mean: 0.93044, std: 0.01483, params: {'n_neighbors': 5, 'metric': 'chebyshev'},
mean: 0.95270, std: 0.00154, params: {'n_neighbors': 5, 'metric': 'minkowski'},
mean: 0.94157, std: 0.00373, params: {'n_neighbors': 5, 'metric': 'l1'},
mean: 0.95270, std: 0.00154, params: {'n_neighbors': 5, 'metric': 'l2'},
mean: 0.94157, std: 0.00373, params: {'n_neighbors': 5, 'metric': 'cityblock'},
mean: 0.79633, std: 0.02058, params: {'n_neighbors': 5, 'metric': 'hamming'},
mean: 0.84474, std: 0.00680, params: {'n_neighbors': 5, 'metric': 'jaccard'},
mean: 0.81024, std: 0.00442, params: {'n_neighbors': 5, 'metric': 'kulsinski'}]
```

best score

```
0.952698942682
```

Entrenamos con el mejor 20 versiones stratificadas del data set.

Datos de accuracy prediciendo con Ytest

```
Accuracy : [0.98484848484848486, 0.9932659932659933,
0.98316498316498313, 0.97979797979797978, 0.97643097643097643,
0.9932659932659933, 0.98484848484848486, 0.98821548821548821,
0.98989898989898994, 0.98989898989898994, 0.98989898989898994,
0.98484848484848486, 0.97979797979797978, 0.98653198653198648,
0.98148148148148151, 0.98316498316498313, 0.98148148148148151,
0.97643097643097643, 0.98821548821548821, 0.98316498316498313]
Media: 0.984932659933
Dev: 00483475773763
```

Esther Garate
Laura de Luis

Datos de accuracy prediciendo con Ytrain
[0.99251870324189528, 0.9900249376558603, 0.9900249376558603, 0.9900249376558603, 0.9900249376558603, 0.98836242726517043, 0.98919368246051542, 0.9908561928512053, 0.9908561928512053, 0.9900249376558603, 0.9908561928512053, 0.99251870324189528, 0.99168744804655029, 0.98836242726517043, 0.9900249376558603, 0.9900249376558603, 0.9900249376558603, 0.9900249376558603, 0.98586866167913545, 0.99251870324189528]
Media train:0.990191188695
Devtrain:0.0015237159418

.

Gráfica de las medias de las accuracys de train y test con k-vecinos = 5, métricas manhattan, euclidean, minkowski, l1, l2, cityblock, haming, jaccard, kulsinski
y estratificando el dataset 20 veces:

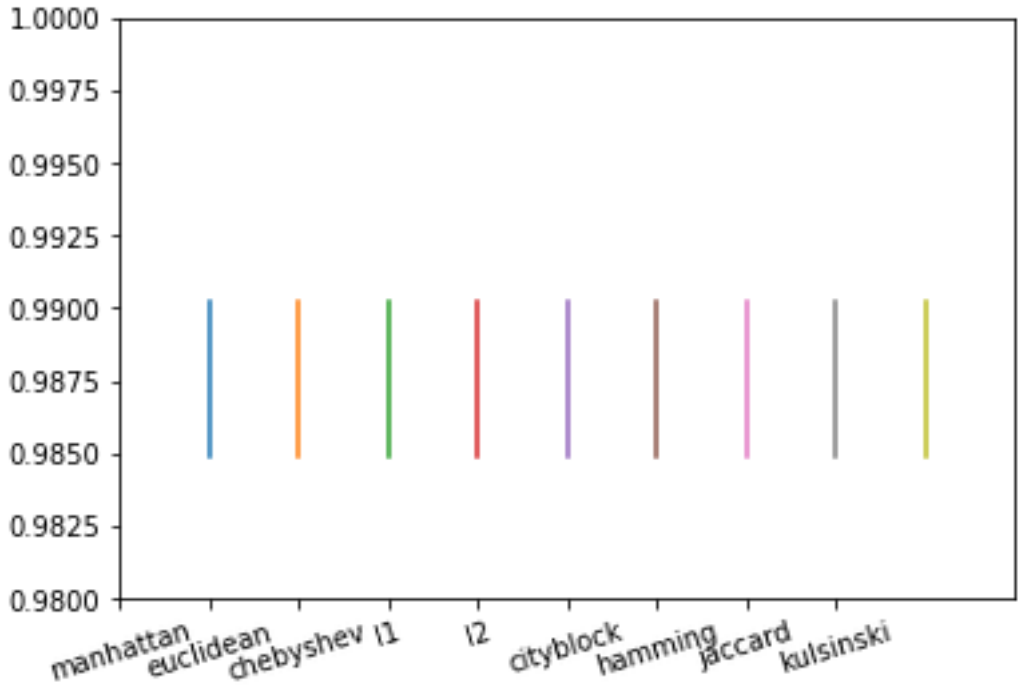

CONCLUSIONES

El mejor modelo elegido para 5 k-vecinos es la métrica euclídea, la que mide la distancia real con la sima de los cuadrados de las coordenadas de los puntos.

Al filtrar este modelo con 20 datasets estratificados y sacar las acuracis vemos que el modelo elegido es consistente ya que la media y desviación son óptimas.

Las “accuracys” para todas las métricas son muy buenas y hay poca diferencia entre una u otra, por lo que los target del dataset están concentrados.